Avaliação de Modelos Text-to-SQL em Português Brasileiro

Métricas: EX — Execution Accuracy · TAS — Taxa de Alucinação de Schema · TVO — Taxa de Violação Operacional

Dataset: BIRD mini-dev — PT-BR · 4 modelos · 3 tracks · 384 execuções

22 de Abril de 2026

Visão Geral do Experimento

Configuração e escopo da avaliação

Dataset

BIRD mini-dev
traduzido para PT-BR

Base financeira tcheca
(banco, clientes,
transações, empréstimos)

32 questões
384 execuções totais

4 Modelos Avaliados

GPT-4o
(OpenAI)

GPT-5.4-mini
(OpenAI)

GPT-5.4
(OpenAI)

sabia-4
(Maritaca AI — modelo BR)

3 Tracks (Pipelines)

Track A
Apenas a pergunta — sem schema

Track B
Schema completo do banco no prompt

Track C
Schema + contexto RAG recuperado
(top-5 chunks por pergunta)

As 3 Métricas Avaliadas

Definições formais e critério de detecção nos dados

(i) EX — Execution Accuracy

Mede se a query gerada produz exatamente o mesmo resultado que a query de referência.

Quanto maior, melhor.

EX = |{q : resultado(gerada) = resultado(ref)}| / |Q|

Detectado por:

rows_equal = True

(ii) TAS — Taxa de Alucinação de Schema

Mede se o modelo referencia tabelas ou colunas inexistentes no banco de dados.

Quanto menor, melhor.

TAS = |{q : ∃ objeto_ref(q) ∉ schema}| / |Q|

Detectado por:

"no such table / column"
(erro retornado pelo SQLite)

(iii) TVO — Taxa de Violação Operacional

Mede qualquer falha de execução SQL.
TAS ⊆ TVO por definição.

Quanto menor, melhor.

TVO = |{q : q contém ≥ 1 violação}| / |Q|

Detectado por:

generated.success = False

Impacto do Contexto — Resultados por Track

128 execuções por track (4 modelos × 32 questões)

Track	EX (%)*	TAS (%)**	TVO (%)***	N
Track A — sem schema	0.0%	91.4%	100.0%	128
Track B — com schema	18.0%	2.3%	6.2%	128
Track C — schema + RAG	29.7%	1.6%	3.1%	128
TOTAL	**15.9%**	**31.8%**	**36.5%**	**384**

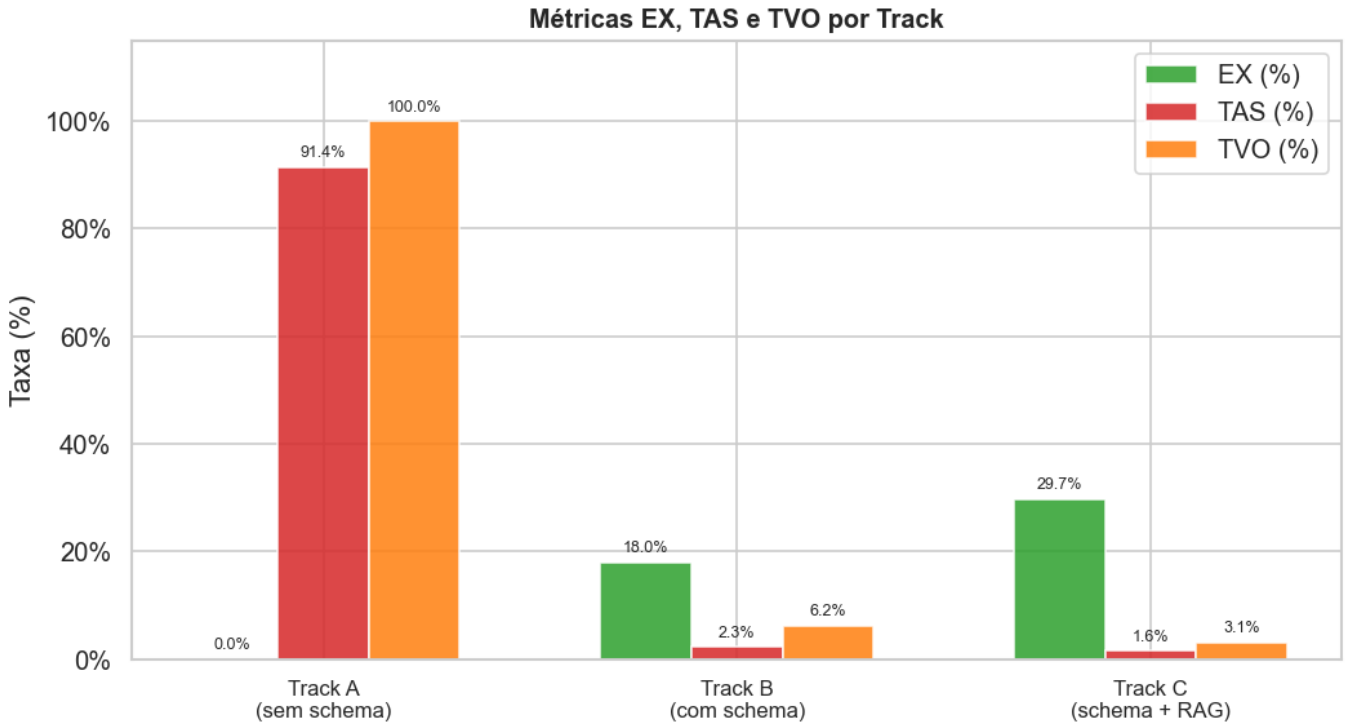

**EX — Execution Accuracy*
***TAS — Taxa de Alucinação de Schema*
****TVO — Taxa de Violação Operacional*

Resultados por Modelo

Agrega as 96 execuções do modelo nas 3 tracks juntas

Modelo	EX (%)*	TAS (%)**	TVO (%)***	N
gpt-4o	15.6%	**32.3%**	**37.5%**	96
gpt-5.4-mini	15.6%	**33.3%**	33.3%	96
gpt-5.4	**18.8%**	26.0%	33.3%	96
sabia-4	13.5%	**35.4%**	**41.7%**	96
TOTAL	**15.9%**	**31.8%**	**36.5%**	**384**

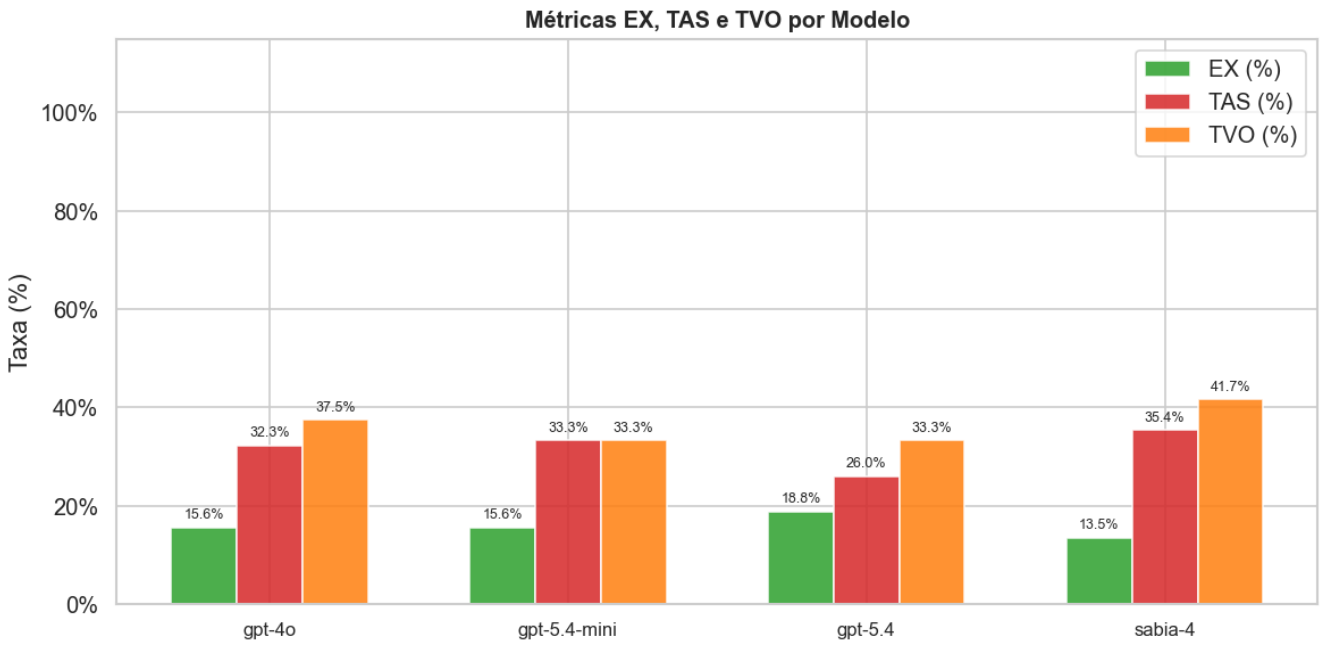

**EX — Execution Accuracy*
***TAS — Taxa de Alucinação de Schema*
****TVO — Taxa de Violação Operacional*

Matrizes Modelo × Track

Visão cruzada das 3 métricas — valores em % de 0 a 100

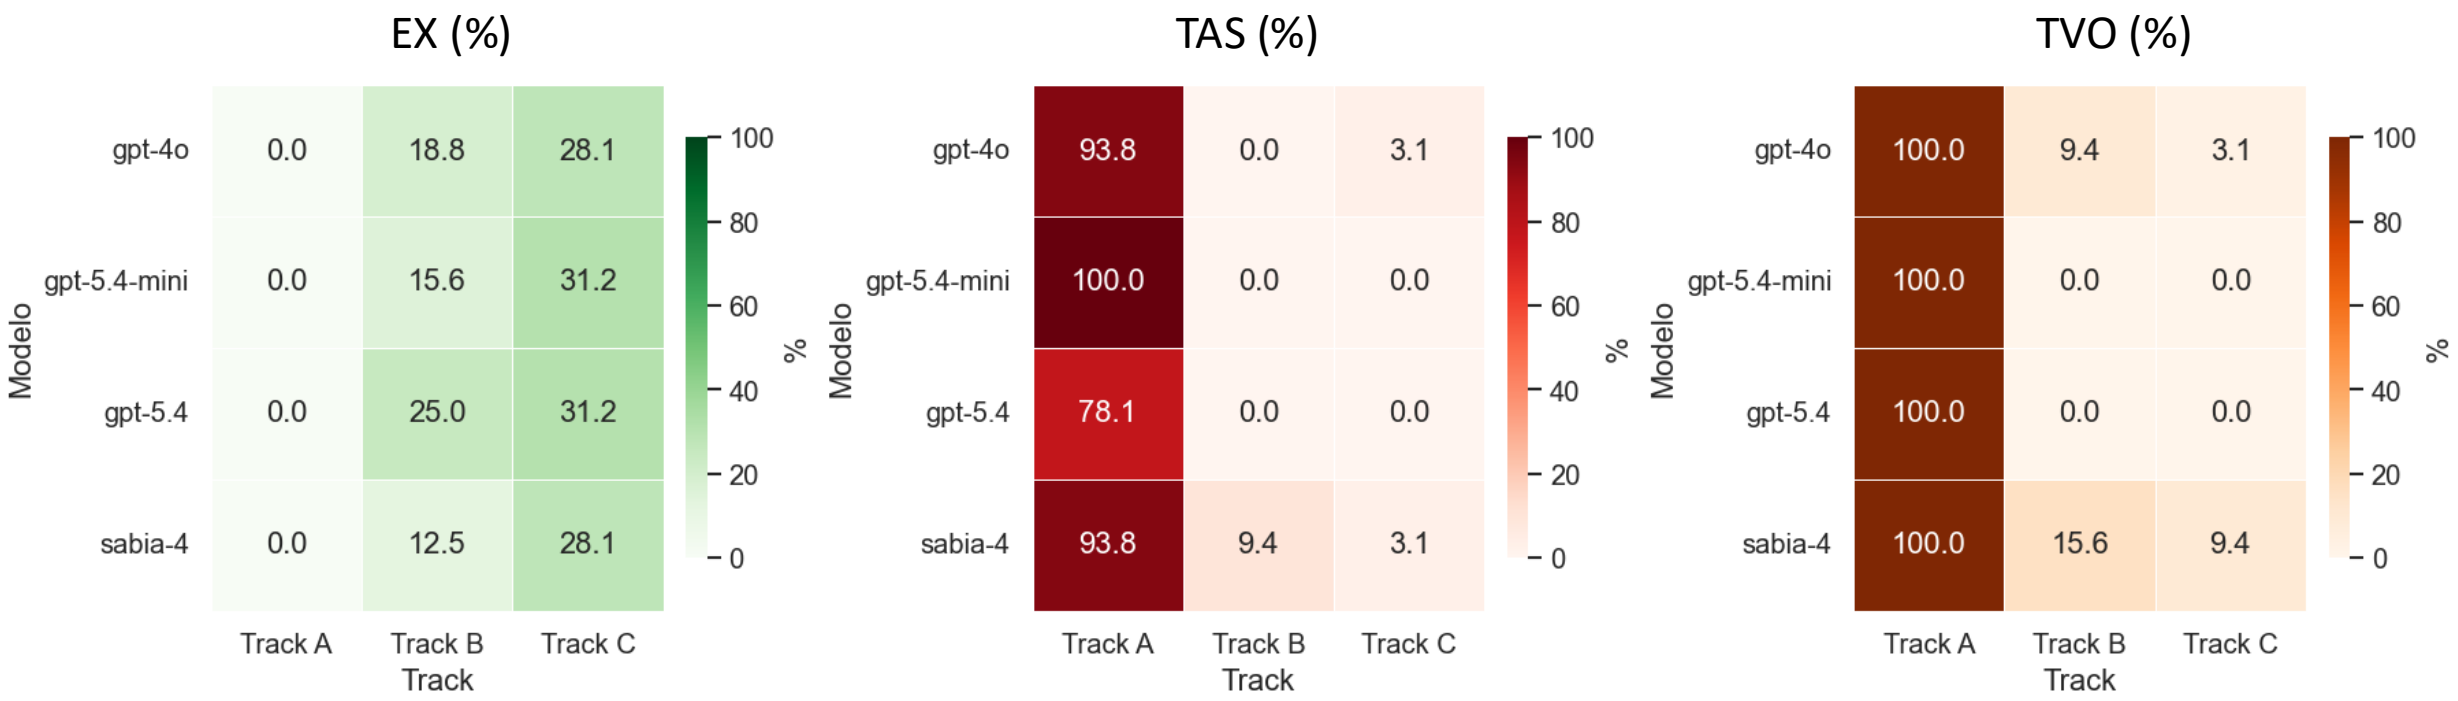

Track A - Apenas a pergunta — sem schema
Track B - Schema completo do banco no prompt
Track C - Schema + contexto RAG recuperado (top-5 chunks por pergunta)

Evolução da EX por Track

Impacto progressivo do contexto fornecido ao modelo

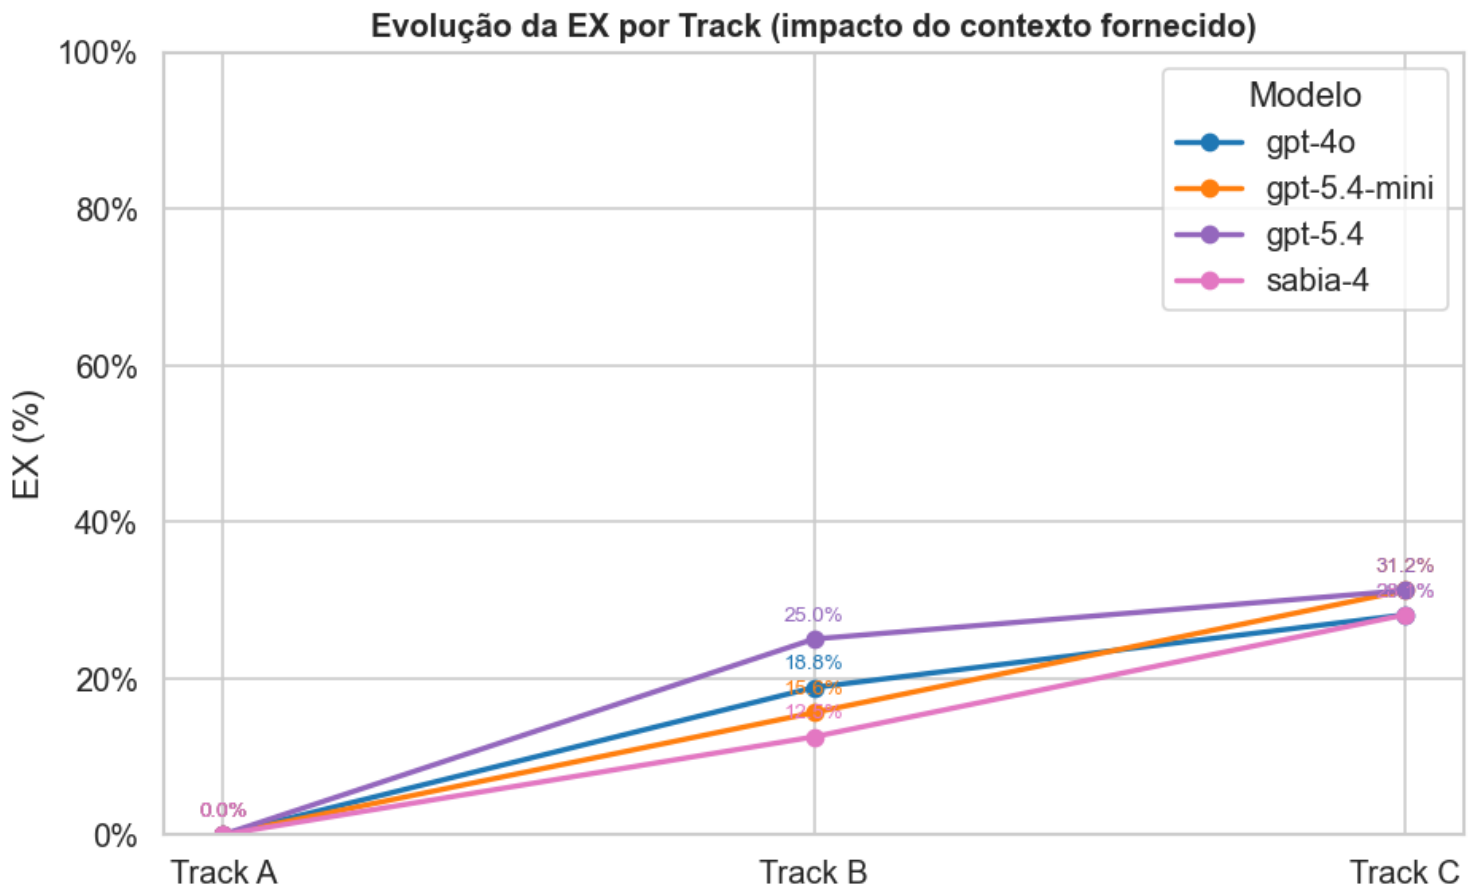

Destaques

Track A — EX = 0% (todos os modelos)

Sem schema → 100%
TVO 91.4% TAS em média

Track A → B: +18.0 p.p.

Só adicionar o schema elimina quase todas as alucinações

Track B → C: +11.7 p.p.

RAG adiciona contexto semântico — melhoria consistente para todos

Melhor Track C:
gpt-5.4-mini (31.2%)

gpt-5.4: mais eficiente
0% TAS/TVO em B e C

Conclusões

Síntese dos resultados experimentais

1. Schema é indispensável

Track A (sem schema):
TVO = 100.0% — TAS = 91.4%
EX = 0.0% para todos os modelos

Sem a estrutura do banco, nenhuma query válida é gerada.

2. RAG amplifica a EX

Track C (schema + RAG):
EX = 29.7% vs Track B: 18.0%
Ganho: +11.7 p.p.

Contexto semântico recuperado reduz ambiguidade das perguntas.

3. gpt-5.4 — mais consistente

Melhor EX global: 18.8%
Menor TAS: 26.0%

Com schema (B/C):
TAS = 0% e TVO = 0%

4. sabia-4 — beneficia do contexto

Maior TVO geral: 41.7%

Track C: EX = 28.1%
Melhora expressiva com RAG

Potencial do modelo brasileiro evidenciado.

Análise da Hipótese vs. Resultados

1. Ganhos mensuráveis e progressivos em EX*
Progressão clara e consistente para todos os 4 modelos.
A – 0%
B – 18%
C – 29,7%

Maior incremento relativo em A → B
A → B: +18,0 p.p.
B → C: +11,7 p.p.
Confirmado. A hipótese central — de que o maior salto ocorre com a chegada do schema — se sustenta com folga.

2. Queda de TAS predominantemente em A → B**
A → B: 91,4% → 2,3% (−89,1 p.p.) — queda dramática
B → C: 2,3% → 1,6% (−0,7 p.p.) — quase nula

Confirmado. Sem schema, praticamente toda query alucina objetos.

3. TVO* com redução progressiva, contribuição incremental da Trilha C**
A → B: 100,0% → 6,2% (−93,8 p.p.)
B → C: 6,2% → 3,1% (−3,1 p.p.)

Direção confirmada, mas o ganho da Trilha C em TVO é modesto — a maior parte da redução já ocorreu na Trilha B.

**EX — Execution Accuracy*
***TAS — Taxa de Alucinação de Schema*
****TVO — Taxa de Violação Operacional*